

Roadmap de mejora – Alma Clinico

Auditoria de código, un experimento reproducible de alucinación de Whisper, y un panel adversarial de 3 revisores sobre cada propuesta de arreglo. **8 tareas, ordenadas por dano evitado primero.** El hallazgo central: el bug de farmacos inventados por la IA **sigue abierto** — no es una promesa de arquitectura resuelta, es un numero medido hoy.

14 jul 2026

EL HALLAZGO

El bug de farmacos sigue abierto

1 de cada 4 consultas SIN farmacos, transcritas con el perfil que corre hoy en produccion, inventa un medicamento. Medido el 14 de julio de 2026, no en una fecha antigua.

EL METODO

Panel adversarial, no una lista de deseos

7 propuestas, 3 revisores independientes por propuesta, obligados a intentar refutarlas contra el código real. Todas sobrevivieron solo con correcciones — ninguna paso intacta.

EL RESULTADO

8 tareas ejecutables, 4 ideas descartadas

Cada tarea trae pasos sin ambigüedad, criterios medibles y rollback. Las ideas que el panel mato quedan documentadas para que nadie las reproponga sin ver por que murieron.

01 Donde estamos de verdad

Sin maquillaje. Verificado de forma directa el 14 de julio de 2026 contra los 4 repos que sostienen la capa clinica de Alma.

REPOS BAJO CONTROL DE VERSIONES

0 de 4

alma-clinico, alma-escriba y copiloto-ficha no tienen .git propio — resuelven al repo de otro proyecto. alma-escriba-v2 tiene .git con 0 commits. **VERIFICADO**

ALUCINACION DE FARMACOS, PERFIL MG COMPLETO, AUDIO SIN FARMACOS

25%

5 de 20 consultas simuladas sin ningun medicamento inventaron uno. Config que corre HOY en produccion. **MEDIDO**

TESTS QUE PASAN AUDIO REAL POR WHISPER

0 de 393

63 tests en alma-clinico + 330 en alma-escriba, todos corren en fracciones de segundo — cero toca el modelo.

VERIFICADO

COBERTURA DE LA FUNCION QUE FILTRA ALERTAS DE SEGURIDAD

0 tests

_filtrar_omisiones_falsas (alma-escriba/app/ai.py:850) suprime banderas de suicidio y alergia hoy, y nadie lo prueba. Corre en produccion con psiquiatria. **VERIFICADO**

TAMANO SIN VERSIONAR DE LOS 4 REPOS CLINICOS

~1,3 GB

248M + 477M + 309M + 266M, dominado por entornos .venv, no por codigo (unos 15-45 archivos .py por repo).

MEDIDO

LOGGING DE LO QUE SE DESCARTA AL TRANSCRIBIR

0 llamadas

El motor arma una lista de segmentos descartados y un recorte silencioso de vocabulario — ningun consumidor los mira.

VERIFICADO

Lo que SI funciona hoy, medido y en produccion (para no perder de vista lo bueno mientras se lee lo malo): el Copiloto de Ficha tiene su verificador de 2a pasada corriendo en `ficha.agentecmc.cl`, y una prueba de sabotaje corrida en produccion el 12 de julio de 2026 detecto tanto una posologia inventada ("Metformina 850 mg cada 12 horas") como una alergia a penicilina omitida. Ese verificador es una red DESPUES del hecho — no reemplaza arreglar la causa en la capa acustica, que es exactamente lo que la Seccion 2 muestra que sigue sin resolverse. Detalle completo de esa arquitectura en el documento a `lma-clinico-arquitectura.html` (uso local del Dr. Olavarria).

02 El bug abierto: farmacos inventados

El hallazgo mas importante de este documento. No es una hipotesis: es un experimento reproducible corrido el 14 de julio de 2026.

VEREDICTO

ABIERTO – no resuelto por ningun trabajo anterior

El perfil completo de medicina general (el que usa **copiloto-ficha**, en produccion hoy con pacientes reales) alucina al menos un farmaco en **1 de cada 4 consultas donde nadie mencionó ninguno**. La unica configuracion medida que llega a 0% de alucinacion sacrifica **mas de un tercio de la captura de farmacos reales** (79% → 42%). Cambiar alucinacion por omision no es un arreglo: es otro dano, distinto pero igual de serio para un sistema clinico.

El experimento

Corpus sintetico de 20 consultas "**droga-cero**" (guiones clinicos completos — resfrio, lumbago, certificado de salud, control de exámenes, mareos — en los que NINGUN farmaco se menciona nunca) mas 3 guiones **con-farmaco** reales (hipertension/diabetes, infeccion, tiroides), cada uno en 3 niveles de ruido de fondo (limpio, medio, intenso) y con audio de 60 a 70 segundos — la duracion de una consulta real, no un clip de laboratorio. Se corrieron 3 configuraciones del motor de transcripcion sobre el mismo corpus exacto.

CORRE HOY EN PRODUCCION

PROD_full_MG

Alucinacion (droga-cero)

25%

Captura (farmacos reales)

79%

5 de 20 consultas sin farmacos inventaron uno. 38 de 48 menciones reales de farmacos se capturaron. Ademas 6 farmacos extra inventados dentro del propio corpus con-farmaco.

SAFE_base

Alucinacion (droga-cero)

0%

Captura (farmacos reales)

42%

Hotwords sin nombres de farmacos (solo examenes). Elimina la alucinacion pero pierde mas de la mitad de los farmacos reales mencionados (20 de 48).

SAFE_base_nohw

Alucinacion (droga-cero)

0%

Captura (farmacos reales)

42%

Sin hotwords en absoluto. Identico a SAFE_base — indica que son los hotwords de FARMACOS especificamente los que causan la alucinacion, no los hotwords en general.

dc_n=20 (consultas droga-cero) · tot=48 (menciones de farmaco esperadas en el corpus con-farmaco) · MEDIDO 2026-07-14 , corpus y resultados en formato JSON conservados junto a este roadmap.

Los 4 casos exactos

dc2_lumbago — dolor lumbar, CERO farmacos en el guion → invento **"losartan"**.

dc3_certificado — control sano / certificado, CERO farmacos → invento **"losartan"**.

dc4_control_examenes — revision de examenes normales, CERO farmacos → invento **"atorvastatina"** en una corrida y **"ciprofloxacino"** en otra.

dc5_mareos — vertigo, CERO farmacos → invento **"atorvastatina"** Y **"amoxicilina"** en la misma consulta.

HALLAZGO AUXILIAR — UNA PISTA, NO UNA SOLUCION PROBADA

Un experimento distinto, sobre el corrector fonetico de farmacos que YA existe en el codigo, recupero correctamente **10 de 10** nombres de farmacos reales deliberadamente fragmentados por el reconocimiento de voz ("lo sartan" → "losartan", "met formina" → "metformina", "amoxi cilina" → "amoxicilina"...), con **0 falsos positivos** sobre 30 frases inocentes. Esto sugiere que combinar **SAFE_base** (sin hotwords de farmacos, para no alucinar) **con el corrector fonetico** (para recuperar farmacos reales mal transcritos) podria lograr baja alucinacion Y buena captura a la vez. Esa combinacion especifica **no fue medida todavia** — es la tarea **NUC-02**

del roadmap, y es la única de las 8 que no paso por el panel adversarial: se agrego para no dejar este hallazgo sin una tarea de arreglo.

Por que esto no se detecto en la verificación anterior. El plan de rediseño del 12 de julio de 2026 (copiloto-rediseño-plan.html) marca su "Etapa 0 — Fix de seguridad Whisper" como *Hecho y verificado*, con una prueba real: 12 segundos de silencio puro sin texto inventado, y 5 de 5 terminos clinicos capturados en voz con silencios intercalados. Esa prueba sigue siendo valida — pero es mas liviana: no uso el perfil COMPLETO de medicina general con hotwords de farmacos activos, ni audio de duracion real (60-70s) con ruido en 3 niveles. Ambos documentos son correctos; describen alcances de verificación distintos. Este roadmap no contradice el trabajo de julio 12 — lo profundiza, y lo que encuentra es que el problema no esta cerrado para el caso que mas importa: una consulta real, con el perfil que de verdad corre en produccion.

03 Que dice el estado del arte 2026

ASR, diarizacion, grounding y verificación — con los numeros que respaldan cada decision de diseno de Alma. Etiquetado por procedencia: **MEDIDO** es este roadmap, **VERIFICADO** es código leído,

ANUNCIADO es un tercero (paper, norma, proveedor), **NO VERIFICADO** es direccion de mercado sin cifra propia confirmada.

Alucinacion de Whisper en salud

ANUNCIADO

38%

Koenecke et al., "Careless Whisper: Speech-to-Text Hallucination Harms", ACM FAccT 2024: ~1% de las transcripciones de Whisper estudiadas contienen alucinaciones, y **38% de esas alucinaciones tienen dano explicito** (violencia, autoridad falsa, farmacos y posologias inexistentes). Las alucinaciones se concentran en los tramos de silencio y ruido — exactamente donde el experimento de la Seccion 2 las reprodujo.

Ya citado en [copiloto-redisenio-plan.html](#) y [alma-clinico-arquitectura.html](#) (12 jul 2026).

Omision vs. alucinacion en notas clinicas

ANUNCIADO

3,45% vs 1,47%

Framework CREOLA, npj Digital Medicine 2025, sobre 12.999 frases anotadas por clinicos: la **omision (3,45%) es mas frecuente que la alucinacion (1,47%)** — y es la que nadie mira. Abridge subio su deteccion combinada de 82% a 97% con una arquitectura de verificador de 2 pasadas, la misma que Alma ya implemento (ver tarjeta de trazabilidad abajo).

Ya citado en [copiloto-redisenio-plan.html](#).

Grounding / Linked Evidence

VERIFICADO EN ALMA

Ya implementado

Anclar cada frase de la nota al segmento de audio/transcripcion que la respalda (citar la fuente, en vez de prosa suelta) es el patron mas copiado del sector 2026 — y Alma ya lo tiene en produccion ([alma_clinico/trazas](#)). Lo que NO cubre: farmacos alucinados DENTRO del propio transcrito (no en la nota generada por el LLM) tienen un segmento fuente valido — por eso el arreglo de la Seccion 2 tiene que vivir en la capa acustica, no solo en el verificador de texto.

Patron: Abridge "Linked Evidence"; implementacion propia verificada 2026-07-14.

Fatiga de alertas

ANUNCIADO

46-96%

Meta-analisis de alertas de soporte de decision clinica (CDS): entre 46% y 96% se descartan sin leer. Reemplazar una alerta interruptiva por CDS pasivo bajo el volumen de alertas 80% (8.206→1.449/semana) y subio la adherencia de 23% a 61%. Es la razon de fondo por la que TRANS-02 (Seccion 4) se recorto a telemetria pasiva y NO a una alerta en vivo.

JMIR Human Factors 2019 / JMIR Med Inform 2020, ya citado en [copiloto-redisenio-plan.html](#).

Diarizacion de hablantes

NO VERIFICADO LOCALMENTE

Gap identificado

Las canalizaciones clinicas de ASR de punta suelen combinar transcripcion con diarizacion (separar la voz del profesional de la del paciente) para estructurar mejor la nota y dar una senal adicional de alucinacion (un turno fabricado que no se puede atribuir a ningun hablante es sospechoso). El motor de Alma hoy transcribe en un solo flujo, sin diarizacion — es una brecha real frente al estado del arte, pero NO forma parte de las 8 tareas aprobadas de este roadmap; queda como candidato para una proxima iteracion.

Guías de seguridad de medicamentos

ANUNCIADO

OMS · ISMP

La Solución 1 de las Patient Safety Solutions de la OMS (medicamentos de nombre o sonido parecido) y la práctica del ISMP (Institute for Safe Medication Practices) establecen que un sistema automatizado NO debe ocultar alertas de seguridad médica. Es la norma detrás de la tarea ESC-01: sobre-alertar es la falla segura, nunca al revés.

Normas internacionales reconocidas, no medición local.

Nota de honestidad sobre esta sección: las cifras de Koenecke, CREOLA, Abridge y CDS ya estaban citadas en los documentos hermanos de este roadmap (fechados 12 de julio de 2026) — se repiten aquí por consistencia, no se re-verificaron de forma independiente en esta ronda. Las únicas cifras 100% nuevas de este documento son las de la Sección 2 (bug abierto), medidas directamente el 14 de julio de 2026.

04 El roadmap

7 propuestas originales del panel adversarial colapsan a **6 tareas ejecutables** (2 pares resultaron ser la misma tarea vista dos veces) más **1 tarea nueva** (NUC-02) que tapa el hueco crítico que las demás daban por resuelto. Las 2 fusionadas quedan documentadas dentro de la tarjeta de su tarea maestra, y completas en alma-roadmap. j son para trazabilidad. Ordenadas por dano evitado primero, luego valor clínico, luego deuda técnica.

NUC-01 · P1

Poner los 4 repos clinicos bajo control de versiones antes de tocar codigo

IMPACTO TRANSFORMADOR

ESFUERZO: HORAS

RIESGO BAJO

COMPONENTE: TRANSVERSAL

PROBLEMA

alma-clinico, alma-escriba y copiloto-ficha no tienen `.git` propio (resuelven a otro repo). alma-escriba-v2 tiene `.git` con 0 commits. ~1,3 GB sin versionar. Sin git no hay diff ni forma de responder "que cambio el dia que fallo" — y todas las tareas siguientes tocan codigo clinico en produccion o semi-produccion.

SOLUCION

git init + `.gitignore` endurecido (extendiendo el que ya existe en 2 de los 4 repos) + verificacion anti-PII ANTES de cualquier commit + commit baseline con tag + decision del dueno sobre el remoto + gate de arbol limpio en el unico script de deploy real que existe hoy.

PASOS CLAVE

- Extender `.gitignore` en los 4 repos (alma-clinico hoy NO excluye `data/` ni `*.db` — hay que agregarlo).
- `git init` en los 3 que faltan; verificar que el repo del HOME no intente trackearlos.
- `git add -A` y verificar CERO archivos `*.db`, `data/audio/` o tokens antes de commitear.
- **Requiere confirmacion puntual del dueno:** el commit, el tag y el push finales no los hace un agente por su cuenta.
- Gate de arbol limpio en `copiloto-ficha/deploy/deploy.sh` antes del `rsync`.

CRITERIOS DE ACEPTACION

- `git rev-parse --show-toplevel` devuelve la carpeta del propio repo, no el HOME, en los 4.
- Cero secretos/PII en `git ls-files` — verificado antes de cualquier push.
- Commit baseline + tag `v-baseline` confirmados por el dueno en los 4 repos.

Dependencias: ninguna (tarea raiz)

Rollback: si el commit filtra PII antes del push, `git reset --mixed HEAD~1`; si ya hubo push, el remoto se recrea. Tareas posteriores se deshacen con `git revert`.

Panel: fusiona NUC-01 y TRANS-03 (misma propuesta vista dos veces por el panel, ambas aprobadas 2/3 con correcciones). Ver ficha TRANS-03 fusionada mas abajo.

Fusionada aqui: **TRANS-03** — cubria 3 de los 4 repos y llegaba a la misma solucion; su aporte (rollback documentado en el README, gate en el deploy) ya esta en los pasos de esta tarjeta.

ESC-01 · P2

Nunca suprimir banderas de riesgo suicida ni de alergia en el verificador de omisiones

IMPACTO TRANSFORMADOR

ESFUERZO: HORAS

RIESGO BAJO

COMPONENTE: ESCRIBA

PROBLEMA

`_filtrar_omisiones_falsas` (alma-escriba/app/ai.py:850, linea decisiva 878) descarta una bandera de omision si CUALQUIER palabra de contenido compartida con la transcripcion aparece como substring en cualquier parte de la nota — ciego a la negacion. Verificado ejecutando el codigo real: bandera de ideacion suicida + nota "Paciente niega ideacion suicida" → **SUPRIMIDA**. Bandera de alergia a penicilina + nota "Sin alergias conocidas" → **SUPRIMIDA**. Son los items #1 y #2 de prioridad que el propio prompt del verificador declara. Corre HOY en produccion con psiquiatria.

SOLUCION

Lista blanca de categorias CRITICAS (suicidio/autolesion, alergia/anafilaxia, embarazo, anticoagulacion, interaccion grave) que se conservan SIEMPRE, saltando el filtro antes de evaluarlo. **Sin ningun requisito de "2 palabras o mas"** — el panel lo rechazo por unanimidad: el caso legitimo que motivo el filtro (sertralina omitida, 1 sola palabra compartida) dejaria de suprimirse, resucitando el falso positivo original. Tampoco se implementa deteccion de negacion en esta tarea (mayor riesgo, queda fuera de alcance).

CRITERIOS DE ACEPTACION

- Bandera de ideacion suicida negada en la nota → llega a la doctora.
- Bandera de alergia contradicha en la nota → llega a la doctora.
- El caso sertralina (1 palabra, otra seccion) SIGUE suprimido.
- 0 regresiones sobre los 330 tests de alma-escriba.

Dependencias: NUC-01**Rollback:** git revert + reinicio del servicio. Sobre-conservar es la falla segura.

Panel: aprobada 3/3 unanime con correcciones. Se elimino el umbral de "2 palabras" y se bajo el esfuerzo estimado de dias a horas.

Resolver el trade-off alucinacion-vs-captura de farmacos en medicina general

IMPACTO TRANSFORMADOR

ESFUERZO: DIAS A SEMANAS

RIESGO MEDIO-ALTO SIN PANEL

COMPONENTE: NUCLEO

PROBLEMA

El bug de la Seccion 2, en forma de tarea: la configuracion de produccion alucina 25% de las veces sobre audio sin farmacos; la unica alternativa medida sin alucinacion pierde 58% de los farmacos reales. Ninguna de las dos es aceptable sin matices.

SOLUCION

No hay arreglo de una linea. Investigar y validar la hipotesis del corrector fonetico + SAFE_base (ver Seccion 2) sobre el mismo corpus, llevar los 4 numeros al dueno, decidir por escrito, desplegar bajo git, y recalibrar el harness de NUC-04 contra la configuracion final.

PASOS CLAVE

- **Urgente:** rescatar el corpus del experimento (audio + resultados) de su directorio temporal a un lugar versionado — se pierde si no se copia a tiempo.
- Someter esta ficha al mismo panel adversarial de 3 revisores antes de ejecutar el cambio de configuracion.
- Medir la 4a configuracion (SAFE_base + corrector fonetico) sobre el mismo corpus.
- Decision del dueno con los 4 numeros lado a lado (ver Seccion 6).

CRITERIOS DE ACEPTACION

- Corpus versionado antes de decidir nada.
- Configuracion candidata medida y comparable con las 3 ya conocidas.
- Decision final documentada por escrito, con numeros, no un cambio silencioso.

Dependencias: NUC-01

Rollback: volver a PROD_full_MG (conocida) via git revert + reinicio de alma-stt.service mientras se reinvestiga.

Panel: NO REVISADA. Agregada al construir este roadmap a partir de evidencia medida directamente, porque NUC-04 dependia de una "NUC-02" que nunca llego con ficha propia al material de origen. Requiere pasar por el mismo panel de 3 revisores antes de ejecutarse — no ejecutar a ciegas.

ESC-03 · P4

Cobertura unitaria determinista de la funcion que decide que alertas NO ve la doctora

IMPACTO ALTO

ESFUERZO: HORAS

RIESGO BAJO

COMPONENTE: ESCRIBA

PROBLEMA

`_filtrar_omisiones_falsas` tiene CERO tests directos — verificado por grep. Los unicos tests relacionados estan marcados live (se saltan sin clave de API) y prueban el prompt, no este filtro determinista.

SOLUCION

6 tests unitarios deterministas, sin red, que fijan el comportamiento correcto de ESC-01 en piedra: banderas criticas negadas se conservan, el caso sertralina se sigue suprimiendo, entradas vacias no rompen nada.

TESTS A ESCRIBIR

- `test_conserva_bandera_suicida_negada`, `test_conserva_alergia_contradicha`
- `test_conserva_categoria_critica_adicional` (embarazo o anticoagulacion)
- `test_suprime_dato_en_otra_seccion` (sertralina, sin el umbral de 2 palabras)
- `test_alucinacion_nunca_pasa_por_este_filtro`, `test_entradas_vacias_no_lanzan`

Dependencias: **ESC-01** (bloqueante estricto: 3 de 6 tests fallan sin ella)

Rollback: tests aditivos, sin efecto en produccion.

Panel: aprobada 3/3 unanime. Se corrigio el conteo de tests preexistentes (319→330, cifra desactualizada) y se elimino la dependencia del umbral de 2 palabras ya rechazado en ESC-01.

Harness de audio real en CI: fixtures doradas que pasan por Whisper de verdad

IMPACTO ALTO

ESFUERZO: HORAS (FRENTE A) + DIAS (FRENTE B)

RIESGO BAJO

COMPONENTE: NUCLEO

PROBLEMA

Ninguno de los 393 tests combinados (nucleo + escriba) hace pasar un solo audio por Whisper. `engine.transcribir()`, el VAD y el servicio HTTP (auth, limite de tamaño, borrado del audio) tienen cero cobertura automatizada — exactamente la capa donde vive el bug de NUC-02.

SOLUCION — DOS FRENTESEPARADOS POR COSTO

Frente A (horas, corre en cada push): smoke test del servicio con el motor mockeado — 401 sin token, 413 sobre el limite, y verificación de que el audio se borra siempre. **Frente B** (días, corre nightly/pre-deploy, DESPUES de NUC-02): fixtures de audio committeadas (no regeneradas en CI) con aserciones de regresión contra el baseline medido — nunca un "0 absoluto" que hoy sería falso.

CRITERIOS DE ACEPTACION

- La suite normal sigue corriendo en menos de 1 segundo e incluye el Frente A.
- La suite de audio ejecuta el modelo de verdad y falla si la alucinación empeora respecto del baseline de NUC-02.
- El job del Frente B no compite por memoria con el servicio en producción.

Dependencias: NUC-01 , NUC-02

Rollback: tests aditivos; si el nightly resulta poco confiable, se desactiva sin tocar producción.

Panel: fusiona NUC-04 y NUC-07 (misma propuesta, dos rondas). Se descarto explícitamente un test de "modo ambient por trozos" que no corresponde a ninguna función existente en el código (ver Sección 5).

Fusionada aquí: **NUC-07** — mismo objetivo, verificación de código menos precisa; su parte de "modo ambient" se descarto, no se fusiono.

PROBLEMA

Hoy nadie se entera si el bug de NUC-02 reaparece o empeora fuera del laboratorio. El motor arma una lista de segmentos descartados que nadie persiste ni mira, y el recorte de vocabulario es silencioso.

SOLUCION (ALCANCE RECORTADO POR EL PANEL)

SOLO telemetria pasiva y local: persistir por consulta los segmentos descartados y las metricas de los farmacos detectados, mas un contador de cuanto vocabulario se recorta. **Sin ningun canal de notificacion externo** — la propuesta original de alertar por WhatsApp fue rechazada explicitamente (ver Seccion 5): la senal que proponia usar no dispara para el modo de falla real, y enviar "farmaco + paciente" por WhatsApp es una fuga de datos de salud.

CRITERIOS DE ACEPTACION

- Cada consulta deja un registro local con sus descartes y metricas.
- Cero integraciones de notificacion externa con datos de paciente.
- El reporte semanal nunca se presenta como garantia de ausencia de alucinaciones.

Dependencias: NUC-01 **Rollback:** telemetria aditiva de solo lectura; git revert sin efecto clinico.

Panel: aprobada 2/3 con alcance fuertemente recortado. El voto disidente completo (invenciones de integracion reales) se preserva en la Seccion 5.

05 Lo que decidimos NO hacer, y por que

Informacion valiosa: evita que alguien reproponga una idea que el panel ya mato con evidencia. Ninguna de las 7 propuestas originales fue rechazada COMPLETA — pero estos 4 mecanismos especificos, dentro de propuestas que sobrevivieron, si lo fueron.

DE LA PROPUESTA ESC-01 Exigir 2 palabras de contenido o mas antes de suprimir una omision

El caso legitimo que motivo el filtro (sertralina omitida) comparte exactamente 1 palabra con la nota. Exigir 2 habria hecho que ese caso YA NO se suprima — resucitando el falso positivo que el filtro existe para evitar. Rechazado por unanimidad de los 3 revisores.

DE LA PROPUESTA TRANS-02 Alertar por WhatsApp o webhook cuando un farmaco aparece con evidencia acustica debil

Refutado por el propio codigo en 3 frentes: el VAD ya filtra el silencio, asi que "sin voz adyacente" nunca dispara para el modo de falla real (ruido que engana al VAD); `no_speech_prob > 0,6` esta documentado como generador de falsos positivos sobre voz legitima (medido: "Me cuesta mucho levantarme en las mananas", `no_speech_prob=0,691`, voz real); y enviar "farmaco + paciente" por WhatsApp contradice el principio de que el audio nunca sale de la maquina propia. Ademias, no existe ninguna funcion de notificacion en estos repos hoy.

DE LA PROPUESTA NUC-07 **Test de que N trozos de 10s ("modo ambient") no amplifican la invencion mas que 1 llamada larga**

No existe ningun modo de transcripcion por trozos en el codigo — es un test para una funcionalidad que no esta construida. Se descarta hasta que esa funcionalidad exista.

DE LA PROPUESTA NUC-07 **Pipeline de CI nightly desde cero, regenerando audio en cada corrida, con asercion absoluta de 0 alucinaciones**

Tres problemas a la vez: no existe integracion continua hoy en estos repos; la herramienta de sintesis de voz usada para regenerar el audio es exclusiva de macOS y un runner nightly tipico no lo es; y la asercion de "0 absoluto" contradice la evidencia medida (la config de produccion tiene 5 de 20 hoy) — el arnes naceria en rojo. Reemplazado por fixtures committeadas y aserciones de regresion contra un baseline medido.

06 **Lo que exige una decision del dueno**

No se automatiza. Ningun agente puede tomar estas decisiones en nombre del Dr. Olavarria.

1 **Host y visibilidad del remoto git privado para los 4 repos.**

NUC-01 deja todo listo para pushear, pero no puede elegir proveedor, organizacion ni convencion de nombres.

2 **Que configuracion de transcripcion adoptar: alucinacion vs. captura de farmacos.**

La decision mas importante de este roadmap. 79% de captura con 25% de riesgo de inventar, o 42% de captura con 0% de invencion. Ninguna es "segura" sin matices — una inventa medicamentos, la otra los pierde.

3 **Migrar alma-escriba al nucleo compartido ahora, o esperar.**

Si no migra, cada arreglo del nucleo (incluidos ESC-01 y NUC-02) hay que aplicarlo a mano en dos lugares — el mismo patron que ya genero una brecha de semanas una vez, segun el propio comentario dejado adrede en el codigo del motor.

4 **Donde corre el harness nightly de audio sin arriesgar el servicio de produccion.**

El VPS de produccion ya corre el modelo Whisper con memoria ajustada; cargar un segundo modelo ahi para testear es jugar con el sistema que atiende consultas reales.

5 **Politica de retencion para los nuevos registros de telemetria.**

¿Heredan la retencion de 7 dias del audio, o pueden conservarse mas tiempo al ser solo metadatos? Debe quedar explicito, no implicito.

6 **Ritmo de ejecucion frente a la carga clinica real.**

6 tareas activas mas una validacion de panel es trabajo de ingenieria real, y el dueno tambien atiende pacientes. Que se hace en paralelo, que espera.

Estas decisiones se suman, no reemplazan, a las ya documentadas en `alma-clinico-arquitectura.html` (redimensionar el droplet, retencion de audio a 7 dias, cifrado en reposo, VPS vs.

07 La competencia

Que tienen ellos que Alma no, y que tiene Alma que ellos no. Sin inflar: lo verificado se marca verificado, lo general de mercado se marca como tal.

LO QUE ALMA TIENE Y LA MAYORIA NO **VERIFICADO**

- ✓ Lectura de Medilink (HIS chileno) por RUT y agenda, en produccion — ningun competidor internacional lo hace, y la API de Medilink no ofrece escritura de fichas a nadie.
- ✓ Catalogo GES completo y real: 103 patologias, 85 garantias, 227 banderas rojas — no una lista generica inventada por un modelo.
- ✓ Vocabulario clinico chileno (modismos incluidos) integrado al motor de transcripcion via hotwords.
- ✓ Constancia GES como 5to documento generado — obligacion legal chilena (Ley 19.966, DS 136/2005) que ningun producto internacional ofrece.
- ✓ Nucleo clinico compartido entre especialidades (arquitectura), no copy-paste de codigo por app.
- ✓ Trazabilidad "Linked Evidence" ya en produccion — el mismo patron mas copiado del sector 2026.

LO QUE EL SECTOR TIENE Y ALMA TODAVIA NO **GENERAL DE MERCADO**

- Diarizacion nativa de hablantes (separar voz del profesional y del paciente) — brecha real, no incluida en las 8 tareas de este roadmap.
- Integraciones EHR de escritura bidireccional con sistemas grandes (Epic, Oracle Health) — en Chile esto es una limitacion estructural del sector, no solo de Alma.
- Escala de validacion clinica publicada y equipos de ingenieria mucho mayores, que permiten iterar mas rapido sobre modelos propios.
- Cobertura multi-pais con aprobaciones regulatorias en varias jurisdicciones.
- Ya existe al menos un competidor operando en Chile con distribucion instalada ("Noa", de Doctoralia) — la diferencia de Alma no es la IA en si, es vivir dentro del flujo real del centro (Medilink, GES, el vocabulario del paciente chileno).

08 Como se mide el exito

Las metricas que hoy NO existen, y que este roadmap obliga a empezar a medir. Sin esto, "arreglado" es una sensacion, no un hecho.

METRICA	HOY	OBJETIVO	COMO SE MIDE
Alucinacion de farmacos en droga-cero (MG, perfil completo)	25% (5/20) MEDIDO	0%, sin bajar la captura de 70%	Harness NUC-04 sobre el corpus de referencia
Captura de farmacos reales mencionados (MG)	79% (config que alucina) / 42% (config segura)	80%+ simultaneo con 0% de alucinacion	Mismo harness, corpus con-farmaco
Supresion de banderas criticas (suicidio, alergia)	no medida, 0 tests	0% de supresion, verificado en cada corrida	Tests de ESC-03 en la suite normal
Cobertura de tests que tocan audio real	0% (0 de 393)	Suite de audio en cada pre-deploy	NUC-04, marcador de test "audio"
Repos clinicos con control de versiones y remoto	0 de 4	4 de 4, baseline + remoto privado	Criterios de aceptacion de NUC-01
Tiempo para revertir un cambio de codigo clinico que sale mal	indefinido	menor a 1 hora	Simulacro de rollback documentado
Vocabulario recortado silenciosamente al cargar un perfil	desconocida	visible en cada carga (informativa)	Log agregado por TRANS-02
Farmacos con evidencia acustica debil detectados	0 (no existe la telemetria)	Reporte semanal legible, sin falsa garantia	Vista de solo lectura de TRANS-02

Este documento sirve para decidir, no para sentirse bien.

El bug de farmacos inventados **sigue abierto**. Sobre-alertar cuesta menos que sub-alertar. Sin control de versiones, ningun arreglo de esta lista es reversible si sale mal. Las 6 tareas ejecutables tienen pasos, criterios y rollback — la unica que no paso por el panel adversarial (NUC-02) es, precisamente, la que resuelve el hallazgo mas importante, y por eso exige pasar por el panel antes de tocar produccion.

Roadmap generado el 14 de julio de 2026 · Fuente completa y ejecutable: `alma-roadmap.json` · Documentos hermanos: `copiloto-redisenio-plan.html`, `alma-clinico-arquitectura.html`.

Roadmap Alma Clinico · Centro Medico Carampangue · Estado verificado al 14 de julio de 2026 · Documento del Dr. Rodrigo Olavarria.

Cada cifra distingue MEDIDO / VERIFICADO / ANUNCIADO / NO VERIFICADO. Ninguna cifra de este documento reemplaza el criterio clinico. Documentos hermanos (`copiloto-redisenio-plan.html`, `alma-clinico-arquitectura.html`) son de uso local, no publicados.